

双重自监督机制在聚类任务中的起源与发展

1. 背景与起源：双重自监督聚类的提出

无监督聚类一直是计算机视觉和机器学习中的挑战课题。在**深度聚类**早期研究中，研究者尝试将**特征学习与聚类**相结合，以提升高维数据聚类效果。例如，2016年华盛顿大学和Facebook AI研究院的Junyuan Xie等人提出了著名的 **Deep Embedded Clustering (DEC)** 方法^①。DEC使用自编码器(autoencoder)进行特征表示学习，同时迭代优化聚类目标：通过学生分布(Student t-distribution)计算初始软聚类分配 Q ，并基于 Q 构造更加尖锐的目标分布 P ，再最小化两者的KL散度来细化聚类^②^①。这一过程相当于**双重自监督：重构误差监督特征提取，分布对齐误差监督聚类划分**，实现了表示学习与聚类优化的联合训练。DEC开创了在深度网络中引入**辅助自监督任务（重构）来促进聚类**的思路，为后续“双重自监督”机制埋下伏笔。

2017年，来自东京大学和Preferred Networks的Hu等人提出 **IMSAT** (Information Maximizing Self-Augmented Training)^③。IMSAT引入了**数据增广不变性**这一自监督信号：通过对同一数据施加随机扰动（如对输入添加小扰动或数据增强），要求模型对原始样本和增强样本输出一致的聚类分配。同时，IMSAT最大化每个样本与其聚类标签之间的互信息（促进输出分布对每个样本具有高置信度且不同样本整体上分布均衡）。这相当于**双目标**：一方面信息最大化使模型学习**判别性强且输出分布尖锐**的聚类标签，另一方面增强一致性保证了模型对输入变化的鲁棒性。该方法在无监督图像分类上取得了当时最先进的结果，证明了**同时优化两个自监督目标**的有效性。

随后，Oxford大学的Xu Ji等人在2019年提出 **IIC** (Invariant Information Clustering)^③。IIC将IMSAT的思想进一步简化为一个**单一但双分支**的目标：给定一张图像的两种随机变换，通过同一个网络分别输出两组聚类概率分布，**最大化这两组分布之间的互信息**^③。如此模型在没有任何标签的情况下直接端到端训练，确保了同一图像的不同视角被分到相同聚类。IIC的提出标志着利用“**双视图**”**一致性来实现自监督聚类**的成熟，将双重自监督机制融入到了聚类目标函数本身中。

综上，**双重自监督机制**的雏形可以追溯到深度聚类方法将**特征学习**和**聚类目标**解耦或联合优化的尝试。从DEC的“**重构+聚类**”双任务框架，到IMSAT/IIC的“**数据增强一致性+信息最大化**”双目标，这些开创性工作奠定了“双重自监督聚类”的理论基础和研究方向^③。

2. 演化发展：关键模型中的双分支/双目标设计

随着上述思想的提出，双重自监督机制在聚类领域得到了迅速发展，不少关键模型引入了**双分支网络结构**或**双目标函数**来提升聚类性能。下面我们按时间顺序追踪这一演化过程，重点介绍几个具有里程碑意义的模型及其双自监督设计。

- **DCCM (ICCV 2019) – Deep Comprehensive Correlation Mining**^④^⑤：北京大学等团队的Wu等人提出在聚类中综合利用多种自监督信号。DCCM框架包含三种自监督目标：①**伪标签监督** (Pseudo-label) – 对当前聚类结果置信度高的样本赋予“伪类别”进行分类训练，以引入类别级别的指导^⑤；②**数据增强不变性** – 利用图像变换生成正负样本对，要求模型对同一图像的不同增强得到相似特征，以提高对输入扰动的鲁棒性^⑤；③**三元互信息约束** – 将实例级特征间的互信息提升到三元组层面，鼓励模型提取更判别的特征表示^⑥。通过**多任务、自监督多重约束**，DCCM在当时取得了**62.3%**的CIFAR-10聚类准确率，比已有最佳方法高出**10.1%**^⑦。DCCM的成功表明，将**双重甚至多重自监督信号融合**是提升聚类效果的有效策略。


• **SCAN (ECCV 2020) – Semantic Clustering by Adopting Nearest Neighbors** ⁸ ⁹：比利时KU Leuven大学的Wouter Van Gansbeke等人提出了SCAN模型，以**两阶段双目标**的方法实现无监督图像分类。首先（步骤1），使用对比学习等自监督预训练（如SimCLR实例辨别任务）学习初步特征表示，然后提取每个样本的k近邻集合 ⁸ ¹⁰。接下来（步骤2），在固定特征提取网络的基础上训练一个**聚类头**，通过**SCAN损失**来优化两个目标：¹¹ 其一，**邻居一致性损失**：鼓励每个图像与其k个近邻的聚类预测分布相似（提高局部语义一致性）；其二，**分类_entropy损失**：对聚类头的输出分布施加约束（如最大化预测的熵或与均匀分布的KL散度），避免所有样本塌缩到同一类 ¹¹。这种双重约束使模型在保持邻居语义聚合的同时，也确保聚类划分的全局均衡。与此前端到端单阶段方法相比，SCAN显著提升了聚类性能：在CIFAR-10上将无监督分类精度提高了**26.6%**，CIFAR-100上提高**25.0%**，STL-10上提高**21.3%** ¹²。值得一提的是，SCAN还是首个在ImageNet上取得较好无监督分类效果的方法 ¹²。SCAN的成功印证了“**预训练特征学习 + 聚类细化**”**双阶段策略**的有效性：通过**双重自监督**（特征自监督预训练 + 聚类一致性训练），可以避免端到端聚类模型过度捕捉低级特征 ¹³，从而得到更具语义判别力的聚类结果。

• **SDCN (WWW 2020) – Structural Deep Clustering Network**：北京邮电大学的Bo等人将双重自监督机制引入**图聚类**领域，提出了将图结构融入深度聚类的SDCN模型 ¹⁴。SDCN由两个分支组成：一个传统DNN自编码器用于学习节点的低维表示，另一个图卷积网络(GCN)用于捕获图邻接结构信息 ¹⁵ ¹⁶。为了统一这两个网络的训练，作者设计了一个**双重自监督模块** ¹⁴：首先利用自编码器输出经过k\$-means初始化聚类中心，计算得到每个样本的软聚类分布\$Q\$（公式11）²，并据此构造目标分布\$P\$（公式12）¹⁷；然后**分别用\$P\$去监督自编码器分支的聚类分布\$Q\$和GCN分支的聚类分布\$Z\$**，形成两个KL散度损失 $\mathcal{L}_{clu}$ 和 $\mathcal{L}_Z$ ¹⁸ ¹⁹。这种机制实现了**双线路协同自监督**：聚类的“软标签”同时指导特征表示更新和图结构表示更新，迫使两分支的一致输出 ¹⁹。SDCN通过融合属性和结构信息，在多个网络数据集上取得了当时最佳的节点聚类效果 ²⁰。该模型凸显了**双重自监督模块**在跨模态聚类中的作用：利用聚类目标同时监督两个不同类型的深度子网络，使其优势互补、共同提升聚类性能。

• **Contrastive Clustering (AAAI 2021) – 对比聚类** ²¹ ²²：四川大学Peng Xi研究组的Li等人提出了**对比聚类(CC)**框架，将对比学习引入聚类并**首次在同一网络中显式融合了实例级和聚类级两种自监督信号** ²²。CC的核心思想是：将样本-特征矩阵的行视为**样本的软标签分布**，列视为**聚类的原型表示** ²³ ²¹。具体实现上，CC对每个输入样本产生两种不同的数据增强视图，通过共享的编码网络得到两个特征向量。一方面，在**实例层面**，将这两个视图作为正样本对，其他样本视图为负样本，采用InfoNCE对比损失拉近正样本特征、区分负样本（实例对比学习）；另一方面，在**聚类层面**，根据当前的聚类分配，将属于同一聚类的样本视为正对、不同聚类的样本视为负对，计算**聚类原型**之间的对比损失 ²¹。为了实现聚类级对比，作者将特征矩阵列作为聚类表示，并设计了聚类投影头来优化聚类中心的区分度 ²¹ ²²。通过**同时优化实例级和聚类级两个对比目标** ²²，CC在六个基准图像数据集上全面刷新了聚类性能纪录 ²⁴。例如，在CIFAR-10上NMI达到**0.705**，CIFAR-100上NMI达到**0.431**，分别比当时最佳方法提升了**19%**和**39%** ²⁵。值得注意的是，**CC证明了实例对比+聚类对比的“双支柱”方案可以产生对聚类任务更友好的特征表征** ²⁶。相较仅有实例对比的模型（只关注样本间差异），加入聚类级目标使模型同时关注**全局聚类结构**，从而显著提高聚类准确率 ²⁷。

• **SACC (Pattern Recognition 2022) – Strongly Augmented Contrastive Clustering** ²⁸ ²⁹：华南理工大学的Deng等人对CC进行了拓展，提出**强增强对比聚类(SACC)**。SACC引入了**三视图对比学习架构**：对每张图像生成一个**强增强视图**和两个**弱增强视图**，通过共享权重的主干网络提取特征 ²⁸。在此基础上，同时考虑两种粒度的对比目标：(1) **实例级**：既利用弱-弱视图对作为正样本对，也利用强-弱视图对作为正样本对，计算多视图的实例InfoNCE损失，增强模型对严重扰动的鲁棒性；(2) **聚类级**：利用一个聚类投影头，将强弱视图的特征分别映射到聚类概率分布，并确保同一图像的强/弱视图在聚类空间上一致，同时不同图像（尤其是经过强扰动后）仍能被正确区分 ²⁸。通过**一套网络同时优化实例和聚类两种对比损失**，SACC成功结合了强数据增广的优势和双重自监督机制。在多个数据集上SACC均取得当时**最优结果**：如CIFAR-10上NMI达到**76.5%**，ImageNet-10上NMI高达**87.7%**，明显超越以往方法 ²⁹。

30。SACC的设计表明,即使在更复杂的增强策略下,双重自监督仍然是提升聚类性能的关键利器。此外,近期还有研究探索了使用动量教师网络稳定训练(如MCC, 2022)以及软原型对比等变体 31 32,进一步丰富了双重自监督聚类的范式。可以预见,双重自监督机制将继续在聚类领域产生深远影响,并与新的技术(如Transformer骨干、跨模态对比等)相结合,催生更强大的无监督聚类模型。



图：SACC模型的双重自监督架构示意图 28。该模型对输入图像 x 生成一个**强增强视图** $T^{(1)}(x)$ 和两个**弱增强视图** $T^{(2)}(x)$, $T^{(3)}(x)$, 通过共享参数的表示编码器 f_{θ} 提取对应的特征向量 $z^{(1)}$, $z^{(2)}$, $z^{(3)}$ (如图中中间红色虚线框所示)。接着,模型使用两个并行的投影头进行对比学习:**实例投影头** g_{θ} (蓝色)对特征进行非线性映射,计算实例级对比损失 L_{instance} ; **聚类投影头** h_{θ} (红色)将特征映射为聚类概率分布 $y^{(1)}$, $y^{(2)}$, $y^{(3)}$, 计算聚类级对比损失 L_{cluster} 。训练过程中,模型最小化实例级和聚类级损失之和,既保证了同一图像的不同增强输出特征接近(实例正样本对在高雄空间距离拉近),又保证了相同聚类的样本在输出空间分布一致 28。这种**双分支+双投影头**设计充分利用了强增强带来的困难样本,对模型进行挑战,从而学习到更加健壮且具有判别力的特征表示;同时聚类投影头约束输出分布,使不同类别的特征分得更开,提升了聚类的可分性。

3. 双重自监督 vs. 单一自监督：核心区别与性能提升

双重自监督机制相较传统单一自监督方法,在训练目标和效果上都存在明显区别：

- **训练信号方面**：单一自监督通常只有一个预训练任务或损失函数。例如,只优化实例级对比(如SimCLR只区分不同图像实例)或只优化重构误差、只优化聚类分配一个目标函数。这种单目标往往侧重于数据的某一方面特征：要么关注全局结构忽略细节,要么关注局部差异缺乏全局聚类信息。而双重自监督同时提供了**两种不同视角的监督信号**,往往一个偏重于**局部**(如实例/邻居一致性),另一个偏重于**全局**(如聚类结构/分类性) 27。这种**互补性**使模型在学习过程中受到更全面的约束,避免了仅靠单一信号可能出现的**塌陷解或偏差**。例如,只有实例对比时,模型可能仅通过记住每张图像的细微噪声特征来区分样本,而缺乏对类别聚类的整体把握;只有聚类目标时,又可能因为缺乏对不同实例的区分力而把不该同类的样本混杂在一起。双重机制则通过同时“拉近正样本、拉远聚类”和“保证聚类分布丰富”,兼顾了**局部判别性和全局结构性** 27。
- **模型结构方面**：许多双重自监督模型采用**双分支结构**(或双模块)。例如CC中有两个投影头分别处理实例和聚类对比 21;SDCN中有自编码器和GCN两套网络 14;SCAN中先后训练了两个网络阶段 8。相较之下,单一自监督模型一般是**单链路**(one-stream)的网络,只完成一个任务。这意味着双重机制下模型参数更新受到来自两个不同源头梯度的影响,更容易形成**多任务学习**的效果,从而学到更普适、更稳健的特征表示。

- **避免低级陷阱**：双重自监督有助于模型跳出利用数据集偏差或低级线索完成任务的“捷径”。例如，SCAN作者指出，一些端到端单阶段聚类容易**绑定在低级特征上**（如颜色、纹理）而忽视语义结构¹³。而通过预训练高层语义特征+邻居一致性约束（双阶段），模型被迫利用更高级的语义信息来聚类，从而得到更语义化的聚类结果¹³。再如，在对比学习中，仅靠实例级任务时模型可能过度依赖于数据增强的设置（如果增强不当，模型可能学到非语义的相似性）；加入聚类级目标（例如确保输出的聚类均衡且有判别性）后，可以**缓解对增广方式的依赖**，引导模型学习更符合类别区分的特征²⁷。
- **性能提升方面**：大量实验证据表明，双重自监督机制能**显著提升聚类效果**。定量上，双重自监督模型在标准聚类指标（如精度Accuracy、归一化互信息NMI、调整兰德指数ARI）上往往比对应的单一机制有大幅提高。例如，Van Gansbeke等报告SCAN相较之前最佳方法在CIFAR-10无监督分类准确率提高了**25%+**¹²；Li等人在CC中实现的CIFAR-100的NMI比只用实例对比的Baseline提升了**近40%**²⁵。这些提升点源于双目标的协同作用：实例级任务提供了**细粒度区别能力**，避免聚类把所有样本混为一团；聚类级任务提供了**全局语义约束**，防止模型仅记住每个实例而无法泛化聚类。在定性上，双重自监督模型学到的特征在降维可视化时往往能形成更加**紧凑且分离清晰**的类簇，对应的聚类标签也更吻合人类语义。例如，CC等方法在CIFAR-10上能够自动聚类出与真实类别几乎完全对应的10个簇，而早期方法常出现一类包含多个语义类别的混杂现象²⁴。因此，可以说双重自监督通过**一举两得**的训练模式，有效地克服了单一自监督的局限，在聚类性能上取得了质的飞跃。

4. 当前主流模型及双重自监督实现方式

在聚类任务中，基于双重自监督机制的最新模型引领着性能纪录。下面列举当前效果突出的几种模型，说明它们如何在结构和目标函数上实现双重自监督，并给出开源代码链接：

- **SCAN (ECCV 2020)** – *Semantic Clustering by Adopting Nearest Neighbors*^{8 12}。结构：两阶段框架，包含预训练特征提取网络和后续的聚类网络。目标：预训练阶段采用自监督表示学习（如SimCLR实例辨别）；聚类阶段通过“邻居一致性损失+聚类分布熵正则”实现双目标¹¹（确保局部相似样本预测一致，全局聚类分布均衡）。代码：开源在GitHub平台（项目名“Unsupervised-Classification”）³³：[GitHub链接](#)。
- **CC (AAAI 2021)** – *Contrastive Clustering*^{22 25}。结构：单阶段端到端框架，一个共享骨干网络后分出两个投影头（实例投影-head和聚类投影-head），对应实例级和聚类级对比学习分支²¹。目标：同时优化实例对比损失 $\mathcal{L}_{\text{ins}}$ （区分不同样本）和聚类对比损失 $\mathcal{L}_{\text{clu}}$ （区分不同聚类），共同提升表示的判别性和聚类结构性^{21 26}。这种双重机制使CC在多个图像聚类基准上取得当时最佳成绩（例如CIFAR-10上Accuracy 85%、NMI 0.705）²⁵。代码：开源提供于作者的SCU X-Learning实验室GitHub仓库²⁵：[GitHub链接](#)。
- **SACC (PR 2022)** – *Strongly Augmented Contrastive Clustering*^{28 29}。结构：三支共享权重的编码器（输入一个强增强视图、两个弱增强视图）+ 两个并行投影头（实例和聚类）²⁸。如上图所示，SACC通过增加第三个“强扰动”视图，使模型在更具挑战的增强下学习。目标：优化实例级InfoNCE损失（包括强-弱、弱-弱正样本对）和聚类级对比损失（保证强弱视图输出的一致聚类分配，同时不同类分开）²⁸。该设计实现了**更加强化的双重自监督**：利用强增强挖掘更高层语义，同时借助双重对比约束稳定训练。SACC在ImageNet-10等数据集上显著领先此前方法（ImageNet-10上NMI达87.7%，ACC 90.5%）³⁰。代码：由作者在GitHub开源实现³⁴：[GitHub链接](#)。
- **SDCN (WWW 2020)** – *Structural Deep Clustering Network*¹⁹。结构：双分支网络（多层感知机自动编码器 + GCN图卷积网络），二者通过“传递层”（delivery operator）交互融合表示^{16 35}。目标：引入双重自监督模块，利用聚类软标签分布 Q 生成目标分布 P ，分别监督DNN分支和GCN分支的聚类输出^{18 19}。同时DNN还优化重构误差，GCN优化图结构传递，实现属性和结构信息的同步自监督。

更新。SDCN证明了在图数据聚类中，将结构信息融入双重自监督框架能有效提升聚类表现。**代码**：开源于GitHub仓库“SDCN”²⁰：[GitHub链接](#)。

上述模型代表了当前聚类任务中双重自监督机制的主流应用。它们的源代码公开有助于研究者复现和拓展相关工作。例如，SCAN的两阶段代码实现详细展示了预训练和聚类细化流程；CC和SACC的源码提供了实例级与聚类级对比损失的具体实现细节；SDCN的代码则体现了如何在异构网络中传递聚类监督信号。这些开源项目为社区提供了宝贵资源，推动了无监督聚类技术的进一步发展。

5. 主要参考文献与代码链接

下表汇总了文中提及的主要论文信息，包括论文标题、作者、发表会议/期刊、年份及对应的开源代码链接：

方法 / 模型	论文标题 (英文)	作者 (第一作者等)	会议/期刊 (年份)	开源代码链接
DEC	Unsupervised Deep Embedding for Clustering Analysis ¹	Junyuan Xie, et al.	ICML 2016	Github (Tensorflow) / Github (PyTorch) ¹
IMSAT	Learning Discrete Representations via Information Maximizing Self-Augmented Training	Weihua Hu, et al.	ICML 2017	Github
IIC	Invariant Information Clustering for Unsupervised Image Classification	Xu Ji, et al.	ICCV 2019	Github
DCCM	Deep Comprehensive Correlation Mining for Image Clustering ⁵	Jianlong Wu, et al.	ICCV 2019	Github
PICA	Deep Semantic Clustering by Partition Confidence Maximisation	Yuyin Huang, et al.	CVPR 2020	Github
SCAN	SCAN: Learning to Classify Images without Labels ³³	Wouter Van Gansbeke, et al.	ECCV 2020	Github
Self-Label	Self-Labeling via simultaneous clustering and representation learning	Yoshihiro Kobayashi (Asano), et al.	CVPR 2020	Github
SDCN	Structural Deep Clustering Network	Deyu Bo, et al.	WWW 2020	Github
CC	Contrastive Clustering ²¹ ²²	Yunfan Li, et al.	AAAI 2021	Github
SACC	Strongly Augmented Contrastive Clustering ²⁸	Xiaozhi Deng, et al.	Pattern Recogn. 2023	Github

¹ DEC原论文未公开官方代码，这里列出的是社区实现版本。

以上列出的文献涵盖了双重自监督聚类机制从提出到发展的核心脉络，以及当前表现领先的方法。通过这些参考资料和开源代码，读者可以进一步深入了解“双重自监督”在聚类任务中的理论与实现细节。展望未来，随着自监督学习的持续演进，双重自监督机制有望与更多新技术融合，为无监督聚类性能的突破提供源源不断的动力。

1 2 14 15 16 17 18 19 20 35 论文解读（SDCN）《Structural Deep Clustering Network》 - 别关注我了，私信我吧 - 博客园

<https://www.cnblogs.com/BlairGrowing/p/15723961.html>

3 8 PowerPoint Presentation

https://wwangansbeke.github.io/pdfs/unsupervised_classification.pdf

4 5 6 7 [1904.06925] Deep Comprehensive Correlation Mining for Image Clustering

<https://arxiv.org/abs/1904.06925>

9 10 11 SCAN, Lets Classify images without Labels ! | by clive fernandes | Medium

<https://clivefernandes777.medium.com/scan-lets-classify-images-without-labels-e31388da9cfd>

12 33 GitHub - wwangansbeke/Unsupervised-Classification: SCAN: Learning to Classify Images without Labels, incl. SimCLR. [ECCV 2020]

<https://github.com/wwangansbeke/Unsupervised-Classification>

13 [2005.12320] SCAN: Learning to Classify Images without Labels

<https://arxiv.org/abs/2005.12320>

21 22 23 24 25 26 27 Contrastive Clustering

<https://yunfan-li.github.io/assets/pdf/Contrastive%20Clustering.pdf>

28 Strongly Augmented Contrastive Clustering | DeepAI

<https://www.deepai.org/publication/strongly-augmented-contrastive-clustering>

29 31 32 Contrastive Clustering Methods

<https://www.emergentmind.com/topics/contrastive-clustering>

30 34 GitHub - dengxiaozi/SACC: Pytorch implementation for the paper "Strongly Augmented Contrastive Clustering".

<https://github.com/dengxiaozi/SACC>